TP 3 - Gestion de l'incertitude avec les réseaux bayésiens

L'objectif de ce TP est de construire un modèle probabiliste permettant de gérer les incertitudes, de façon à répondre à des questions dans le domaine de la génétique. Au cours de ce TP vous utiliserez la bibliothèque Python pgmpy, qui permet la manipulation de modèles graphiques probabilistes et des réseaux bayésiens en particulier.

Pour cette séance deux fichiers .py vous sont fournis : bayesnet.py qui fournit l'implémentation du modèle d'illustration vu en cours et genetics.py qui contient le code à compléter.

1 Contexte

Les versions mutées du gène GJB2 [1] sont l'une des principales causes de déficience auditive chez les nouveau-nés. Chaque personne est porteuse de deux versions du gène, ce qui signifie que chaque personne peut posséder 0, 1 ou 2 copies de la version GJB2 de la déficience auditive.

À moins qu'une personne ait réalisé un test génétique, il est difficile de savoir combien de copies du gène muté possède une personne. Il s'agit d'un « état caché », c-à-d une information qui a un effet qui peut être observé (déficience auditive), mais que nous ne connaissons pas directement. Certaines personnes peuvent en effet avoir 1 ou 2 copies de GJB2 muté, mais ne pas présenter de déficience auditive, tandis que d'autres peuvent n'avoir aucune copie mutée de GJB2, mais présenter une déficience auditive.

Afin d'étudier les risques d'apparition du gène muté chez les membres de différentes familles, nous décidons d'établir des réseaux bayésiens ayant pour variables des paires (G_p,T_p) pour chaque personne p. G_p représente le nombre de gènes mutés (0, 1 ou 2) portés par par la personne p. Chaque personne p a également une variable T_p indiquant avec une valeur oui/non si la personne a le trait caractéristique du gène étudié, c-à-d une déficience auditive. Cette variable T_p peut être vue comme dépendante de G_p puisque la probabilité d'avoir une déficience auditive augmente avec le nombre de copies du gène muté. De plus, les relations de parenté permettent de prendre en compte les risques d'apparition liés à l'hérédité génétique, à l'aide des dépendances entre des variables G en relation directe de parenté.

2 Définition des distributions de probabilité

Les distributions de probabilité nécessaires au calcul des probabilités jointes de toutes les variables peuvent être déterminées à l'aide des informations qui suivent.

2.1 Tableaux de probabilité

Quand aucune donnée n'est connue sur les parents d'une personne, la probabilité du nombre G de versions mutées du gène de cette personne est donnée par la probabilité *a priori* de la figure 1a. La probabilité d'apparition du trait caractéristique T est déterminée en fonction du nombre G de versions mutées du gène par le second tableau de la même figure (Fig. 1b).

1. `https://fr.wikipedia.org/wiki/Connexine_26`

Gene	2	1	0
P(Gene)	0,01	0,03	0,96

(a) Probabilité *a priori* P(Gene)

Gene	2	1	0
P(Trait=vrai|Gene)	0,65	0,56	0,01
P(Trait=faux|Gene)	0,35	0,44	0,99

(b) Probabilité conditionnelle P(Trait|Gene)

FIGURE 1 – Définition des probabilités.

Question

1. À partir de ces deux tableaux de valeur fournis, complétez les fonctions du fichier genetics.py get_probs_gene_ancestor() pour $P(G)$ et get_probs_trait() pour $P(T|G)$. Vous pourrez vous aider de la définition des probabilités conditionnelles TabularCPD pour l'exemple donné dans le fichier bayesnet.py. N'hésitez pas également à consulter la documentation officielle de cette bibliothèque, notamment les tutoriel *Defining CPDs* : `https://pgmpy.org/examples.html`.

2.2 Héritage et mutation du gène

Quand le père et la mère d'une personne sont connues, il est possible de prendre en compte les liens génétiques dans la dépendance entre les variables G (un gène par chromosome). Le gène GJB2 auquel nous nous intéressons ici est porté par la 13e paire de chromosomes. Chaque enfant hérite d'une copie du gène GJB2 de chacun de ses parents. Si un parent possède deux copies du gène muté, il le transmettra à l'enfant. Si un parent n'a aucune copie du gène muté, il ne transmettra pas le gène muté à l'enfant. La figure 2 présente un exemple de recombinaison de chromosomes à partir de parents porteurs d'une seule version mutée et d'aucune version.

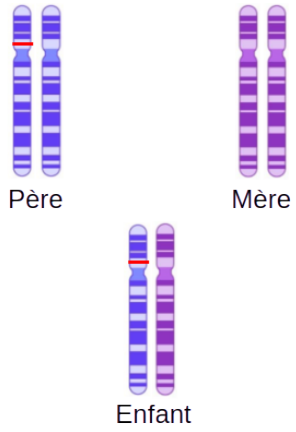


FIGURE 2 – Exemple de recombinaison des chromosomes de la 13e paire avec un père porteur d'une version mutée du gène GJB2 et une mère saine.

Après qu'un gène soit transmis, il a une certaine probabilité de subir d'autres mutations : il passe d'une version du gène à une autre, c-à-d d'une version entraînant une déficience à une version saine et vice-versa. La probabilité de mutation est fixée à 0,01 dans nos cas d'étude.

Questions

1. Calculez dans un premier temps la probabilité que le chromosome hérité d'un des parents (père ou mère) porte exactement 1 version mutée du gène, en connaissant le nombre de versions

mutées de ce parent (fonction get_probs_heredity1()). Dans ce calcul, il vous faudra prendre en compte le fait d'hériter de l'un ou l'autre des deux chromosomes du parent, ainsi que la probabilité de mutation.

2. À partir de la fonction précédente, définissez $P(G_{\text{enfant}} \mid G_{\text{père}}, G_{\text{mère}})$ dans la fonction get_probs_gene() en remplissant un tableau de probablités de type TabularCPD.

3 Cas d'étude : famille n°1

Votre tâche dorénavant est de définir un réseau bayésien pour faire des déductions sur les membres de la famille décrite dans la figure 3.

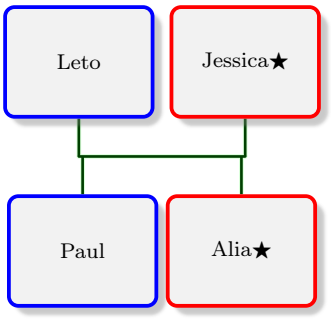


FIGURE 3 – Famille n°1.

Questions

1. Construisez le réseau bayésien associé à la famille, en définissant les variables nécessaires, leurs dépendances, puis les distributions de probabilités conditionnelles et *a priori* en réutilisant les fonctions codées précédemment. Vérifiez ce modèle graphiquement et avec la fonction check_model(). Pour vous aider, un exemple de construction du réseau bayésien présenté en cours avec la bibliothèque pgmpy vous est donné dans le fichier bayesnet.py.
2. Par inférence exacte, prédire G pour Paul, en sachant les valeurs des variables T (les personnes ayant une déficience auditive sont indiquées par une étoile dans la figure 3).
3. Par inférence exacte, prédire G pour Paul, en sachant en plus que Jessica et Alia ont respectivement 1 et 2 versions défectueuses du gène.
4. Réalisez la dernière prédiction à l'aide d'une inférence approchée par échantillonnage et comparez les résultats obtenus avec ceux de l'inférence exacte.

4 Cas d'étude : famille n°2

Dans cette dernière partie, vous aurez à étudier la famille plus élargie décrite dans la figure 4. Les personnes présentant une déficience auditive sont là aussi indiquées par une étoile.

Questions

Définissez un réseau bayésien propre à cette famille, puis répondez aux questions suivantes à l'aide d'une inférence exacte :

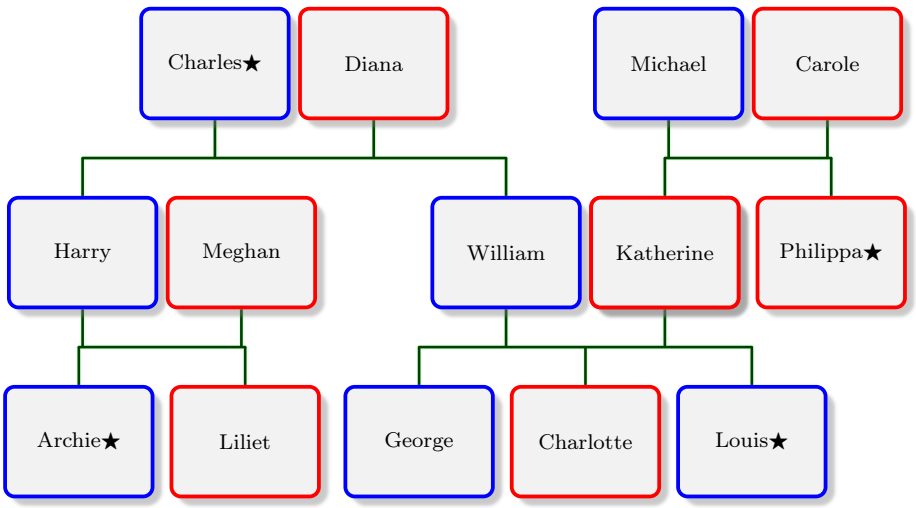


FIGURE 4 – Famille n°2.

1. Prédire G pour George d'une part et pour Liliet d'autre part, en sachant les valeurs observées des variables T,
2. On sait dorénavant que Katherine n'a aucune version défectueuse du gène. Comment évoluent la prédiction de G pour George, ainsi que celle de G pour Liliet ?